

1 Statistique Exploratoire

1.1 Tendence centrale

• **Moyenne** : $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$

• **Médiane** ($med(y)$)

Si n impair : $med(y) = y_{(\lceil n/2 \rceil)}$

Si n pair : $med(y) = \frac{1}{2} (y_{(n/2)} + y_{(n/2+1)})$

• **Quantile d'ordre** $p \in (0, 1)$:

$\hat{q}(p) = y_{(\lceil np \rceil)}$.

• **Quartiles** : Inférieur $\hat{q}(0.25) = y_{(\lceil n/4 \rceil)}$,

Supérieur $\hat{q}(0.75) = y_{(\lceil 3n/4 \rceil)}$.

1.2 Dispersion & Forme

• **Variance empirique** (s^2) :

$$s^2 = \frac{1}{n-1} \sum_{j=1}^n (y_j - \bar{y})^2$$

$$= \frac{1}{n-1} \left(\sum_{j=1}^n y_j^2 - n\bar{y}^2 \right)$$

• **Écart-type empirique** : $s = \sqrt{s^2}$.

• **Étendue (Range)** : $y_{(n)} - y_{(1)}$.

• **Étendue interquartile** : $IQR(y) = \hat{q}(0.75) - \hat{q}(0.25)$.

• **Boxplot** : Construit sur la *five-number summary* ($y_{(1)}, \hat{q}(0.25), med, \hat{q}(0.75), y_{(n)}$).

Seuil maximal des moustaches : $C = 1.5 \times IQR$. Les moustaches s'arrêtent aux valeurs réelles les plus extrêmes contenues dans $[\hat{q}(0.25) - C, \hat{q}(0.75) + C]$. Les points au-delà sont des valeurs aberrantes.

2 Théorie des Probabilités & Théorèmes

2.1 Changement de Variable ($X \rightarrow Y$)

Pour $Y = g(X)$ avec g strictement croissante :

$$F_Y(y) = \mathbb{P}(g(X) \leq y) = \mathbb{P}(X \leq g^{-1}(y)) = F_X(g^{-1}(y))$$

• **Exemple exponentiel** ($Y = e^X$) :
 $\mathbb{P}(Y > 10) = \mathbb{P}(e^X > 10)$
 $= \mathbb{P}(X > \ln(10)) = 1 - F_X(\ln(10))$

• **Formule des densités** ($g \in C^1$ Biject)
 $f_Y(y) = f_X(g^{-1}(y)) \times \left| \frac{d}{dy} g^{-1}(y) \right|$

2.2 Théorème de Bayes

$$\mathbb{P}(A_i|B) = \frac{\mathbb{P}(B|A_i)\mathbb{P}(A_i)}{\sum_{j=1}^k \mathbb{P}(B|A_j)\mathbb{P}(A_j)}$$

• **Forme simple** : $\mathbb{P}(A|B) = \frac{\mathbb{P}(B|A)\mathbb{P}(A)}{\mathbb{P}(B)}$
($\mathbb{P}(B) = \mathbb{P}(B|A)\mathbb{P}(A) + \mathbb{P}(B|A^c)\mathbb{P}(A^c)$).

2.3 Espérance, Variance

$$\mathbb{E}(X) = \sum_i \mathbb{E}(X|A_i)\mathbb{P}(A_i)$$

$$\mathbb{E}(X) = \sum_i x_i \mathbb{P}(X = x_i)$$

$$\mathbb{E}(X) = \int_{-\infty}^{+\infty} x f_X(x) dx$$

$$Var(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2$$

• **Cas univarié** (X) :

$$Var(X) = \sum_i (x_i - \mathbb{E}(X))^2 \mathbb{P}(X = x_i)$$

$$Var(X) = \int_{-\infty}^{+\infty} x^2 f_X(x) dx - \mathbb{E}(X)^2$$

• **Propriétés fondamentales** :

$$Var(aX + b) = a^2 Var(X)$$

$$Var(X \pm Y) = Var(X) + Var(Y) \pm 2cov(X, Y)$$

Si X, Y indépendantes : $Var(X \pm Y) = Var(X) + Var(Y)$

2.4 Fonction de Survie

Soit X une variable aléatoire continue de densité $f(x)$ et de fonction de répartition $F(x) = \mathbb{P}(X \leq x) = \int_{-\infty}^x f(t) dt$. La fonction de survie $S(x)$ est :

$$S(x) = \mathbb{P}(X > x) = 1 - F(x) = \int_x^{+\infty} f(t) dt$$

Propriété de reconstruction :

$$f(x) = -\frac{d}{dx} S(x)$$

2.5 Covariance & Corrélation théoriques

• **Covariance** : Mesure de dépendance linéaire.

$$cov(X, Y) = \mathbb{E}[\{X - \mathbb{E}(X)\}\{Y - \mathbb{E}(Y)\}] = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$$

Propriétés de la covariance :

$$cov(X, Y) = cov(Y, X)$$

$$cov(X, X) = var(X).$$

$$cov(X + Y, Z + W) = cov(X, Z) + cov(Y, Z) + cov(X, W) + cov(Y, W).$$

$$cov(aX + b, cY + d) = ac \cdot cov(X, Y).$$

$$var(X \pm Y) = var(X) + var(Y) \pm 2cov(X, Y).$$

Si X, Y indépendantes $cov(X, Y) = 0$ (la réciproque est fausse).

• **Corrélation** ($\rho_{X,Y}$) : Dimensionnelle, normalisée par Cauchy-Schwarz.

$$\rho_{X,Y} = \frac{cov(X,Y)}{\sqrt{var(X)var(Y)}} \implies -1 \leq \rho_{X,Y} \leq 1$$

Propriétés de la corrélation :

$$\rho(a + bX, c + dY) = \text{sign}(bd)\rho(X, Y).$$

$\rho(X, X) = 1$ et $\rho(X, -X) = -1$ (si X non constante).

$\rho_{X,Y} = 0$ n'implique pas l'indépendance (relation non linéaire possible).

• **Corrélation empirique** :
Pour un échantillon de paires $(x_1, y_1), \dots, (x_n, y_n)$:

$$r = \frac{\sum_{j=1}^n (x_j - \bar{x})(y_j - \bar{y})}{\sqrt{\sum_{j=1}^n (x_j - \bar{x})^2 \sum_{j=1}^n (y_j - \bar{y})^2}}$$

2.6 Comportements Limites (LGN)

Soit $X_1, X_2, \dots$ une suite de variables i.i.d. d'espérance μ .

• **Loi faible des grands nombres** : Si $var(X_1) < \infty$, alors pour tout $\epsilon > 0$:

$$\mathbb{P}(|\bar{X}_n - \mu| \geq \epsilon) \rightarrow 0 \quad \text{quand } n \rightarrow \infty$$

Convergence en proba

• **Loi forte des grands nombres** : Nécessite uniquement $\mathbb{E}(X_1) < \infty$:

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} \bar{X}_n = \mu\right) = 1$$

Convergence quasi sûre

2.7 Théorème Central Limite (TCL) & Delta

• **TCL** : Si $0 < \sigma^2 = Var(X_i) < \infty$, alors la variable standardisée converge en loi :

$$Z_n = \frac{\bar{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$$

or

$$\frac{S_n - n\mathbb{E}[X_1]}{\sqrt{n \cdot Var(X_1)}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$$

$$\implies \bar{X}_n \overset{app}{\approx} \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

• **Méthode Delta** : Soit g une fonction continûment dérivable en μ telle que $g'(\mu) \neq 0$. Alors :

$$\sqrt{n} \frac{g(\bar{X}_n) - g(\mu)}{\sigma} \xrightarrow{\mathcal{L}} \mathcal{N}(0, [g'(\mu)]^2)$$

$$\implies g(\bar{X}_n) \overset{app}{\approx} \mathcal{N}\left(g(\mu), \frac{[g'(\mu)]^2 \sigma^2}{n}\right)$$

2.8 Quantiles théoriques

Pour une fonction de répartition F , le p -ième quantile est $x_p = \inf\{x : F(x) \geq p\}$. Si F est continue et strictement croissante, $x_p = F^{-1}(p)$. La médiane théorique correspond à $x_{0.5}$.

3 Estimation Ponctuelle

Soit un échantillon $X_1, \dots, X_n \overset{iid}{\sim} f(x; \theta)$.

3.1 Méthode des Moments (MOM)

Égalisation des moments théoriques $m_k(\theta) = \mathbb{E}_\theta(X^k)$ et empiriques $\hat{m}_k = \frac{1}{n} \sum X_i^k$.

3.2 Maximum de Vraisemblance (ML)

Vraisemblance $L(\theta) = \prod_{i=1}^n f(x_i; \theta)$
log-vraisemblance $l(\theta) = \sum_{i=1}^n \log f(x_i; \theta)$.

L'estimateur $\hat{\theta}_{ML}$ vérifie l'équation de score $l'(\hat{\theta}_{ML}) = 0$ et la condition de concavité $l''(\hat{\theta}_{ML}) < 0$.

3.3 Propriétés & Optimisation d'EQM

• **Biais** : $b_\theta(\hat{\theta}) = \mathbb{E}_\theta(\hat{\theta}) - \theta$.

• **Erreur Quadratique Moyenne** :

$$EQM_\theta(\hat{\theta}) = Var_\theta(\hat{\theta}) + [b_\theta(\hat{\theta})]^2$$

• **Cas de l'estimateur de la variance sous** $\mathcal{N}(\mu, \sigma^2)$:

Soit $\hat{\sigma}_n^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$. On définit la famille d'estimateurs $\hat{\sigma}^a = a\hat{\sigma}_n^2$. Sachant que $\mathbb{E}(\hat{\sigma}_n^2) = \frac{n-1}{n}\sigma^2$ et $Var(n\hat{\sigma}_n^2) = 2\sigma^4(n-1)$:

• **Bias null** : $a = \frac{n}{n-1} \implies S_n^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$

• **Var nulle** : $a = 0 \implies$ Var nulle, EQM maximal ($= \sigma^2$)

• **Min l'EQM** : $a = \frac{n}{n+1} \implies \frac{1}{n+1} \sum (X_i - \bar{X})^2$

3.4 Information de Fisher & Asymptotique

• **Information de Fisher Théorique** :

$$I_1(\theta) = -\mathbb{E}_\theta \left[\frac{\partial^2}{\partial \theta^2} \log f(X_1; \theta) \right]$$

$$\implies I_n(\theta) = n \cdot I_1(\theta) = -\mathbb{E}_\theta(l''(\theta))$$

• **Information de Fisher observée** : $J_n(\hat{\theta}_{ML}) = -l''(\hat{\theta}_{ML})$.

• **Variance Asymptotique** : $\frac{1}{J_n(\hat{\theta}_{ML})}$

• **Propriété asymptotique** : Pour les modèles réguliers, quand $n \rightarrow \infty$:
 $\hat{\theta}_{ML} \overset{app}{\approx} \mathcal{N}\left(\theta, \frac{1}{I_n(\theta)}\right) \approx \mathcal{N}\left(\theta, \frac{1}{J_n(\hat{\theta}_{ML})}\right)$

Attention : Échoue pour les modèles non réguliers où le support dépend du paramètre (ex : Uniforme $U(0, \theta)$).

3.5 Loi de Pareto (Queues Lourdes)

Densité $f(x) = \alpha x^{-1-\alpha}$ sur $[1, \infty)$ pour $\alpha > 0$. Moment d'ordre r : $\mathbb{E}(X^r) = \frac{\alpha}{\alpha-r}$ si $r < \alpha$, et ∞ si $r \geq \alpha$. Ainsi, $\mathbb{E}(X) < \infty \iff \alpha > 1$ et $Var(X) < \infty \iff$

$\alpha > 2$. Si les moments n'existent pas, le TCL et les propriétés standard des variances/corrélations s'effondrent.

4 Intervalles de Confiance (IC)

4.1 Théorie des Pivots

$T(Y, \theta)$ est un **pivot** si sa loi exacte est connue et indépendante de θ . On résout $\mathbb{P}_\theta(a \leq T(Y, \theta) \leq b) = 1 - \alpha$ pour isoler θ .

4.2 IC - Cas de la Loi Normale $\mathcal{N}(\mu, \sigma^2)$

• **Si σ^2 connue :**

Pivot $Z_n = \sqrt{n} \frac{\bar{Y}_n - \mu}{\sigma} \sim \mathcal{N}(0, 1)$.

IC bilatéral $(1 - \alpha)$: $\left[\bar{Y}_n \pm \frac{z_{1-\alpha/2}}{\sqrt{n}} \sigma \right]$

• **Si σ^2 inconnue :** Estimée par S_n^2 . Pivot $T_n = \sqrt{n} \frac{\bar{Y}_n - \mu}{S_n} \sim t_{n-1}$.

IC bilatéral $(1 - \alpha)$: $\left[\bar{Y}_n \pm \frac{t_{n-1, 1-\alpha/2}}{\sqrt{n}} S_n \right]$

IC unilatéral gauche : $\left[\bar{Y}_n - \frac{t_{n-1, 1-\alpha}}{\sqrt{n}} S_n, \infty \right[$

• **Propriété des quantiles :** La loi de Student ayant des queues plus lourdes, $|t_{n-1, \beta}| > |z_\beta|$ pour tout $\beta \neq 0.5$. Quand $n \rightarrow \infty$, $t_{n-1} \rightarrow \mathcal{N}(0, 1)$.

4.3 Pivots Exacts Non Normaux

• **Cas Uniforme $U(0, \theta)$:** Soit $M_n = \max(Y_i)$. Le pivot est $T = \frac{M_n}{\theta}$. Fonction de répartition : $F_T(t) = \mathbb{P}_\theta(T \leq t) = t^n$ pour $t \in (0, 1)$. Pour un niveau $1 - \alpha$, en choisissant l'intervalle symétrique en probabilité sur T : $\mathbb{P}_\theta(\alpha^{1/n} \leq T \leq 1) = 1 - \alpha$. En inversant :

IC exact $(1 - \alpha)$: $\left[M_n, \alpha^{-1/n} M_n \right]$

4.4 IC Asymptotiques ($n \rightarrow \infty$)

• **Via l'EMV et l'Information observée :** $\theta \in \left[\hat{\theta}_{ML} \pm \frac{z_{1-\alpha/2}}{\sqrt{J_n(\hat{\theta}_{ML})}} \right]$

• **Via le TCL (Exemple de la loi Uniforme $U(0, \theta)$) :**

$\mathbb{E}(Y) = \frac{\theta}{2}$, $Var(Y) = \frac{\theta^2}{12} \implies Z_n = \frac{\sqrt{n}(\bar{Y}_n - \theta/2)}{\sqrt{\theta^2/12}} \overset{app}{\sim} \mathcal{N}(0, 1)$. En résolvant l'inéquation $|Z_n| \leq z_{1-\alpha/2}$ par rapport à θ , on obtient :

$$\theta \in \left[\frac{\bar{Y}_n}{\frac{1}{2} + \frac{z_{1-\alpha/2}}{\sqrt{12n}}}, \frac{\bar{Y}_n}{\frac{1}{2} - \frac{z_{1-\alpha/2}}{\sqrt{12n}}} \right]$$

5 Régression Linéaire Simple

Modèle : $y_j = a + \beta x_j + \epsilon_j$ avec $\epsilon_j \overset{iid}{\sim} \mathcal{N}(0, \sigma^2)$ et x_j fixés non tous égaux.

5.1 Optimisation & Moindres Carrés (MCO)

Minimisation de la somme des carrés résiduels $S(a, \beta) = \sum \{y_j - (a + \beta x_j)\}^2$. Matrice Hessienne globale du système :

$$H = \begin{pmatrix} 2n & 2n\bar{x}_n \\ 2n\bar{x}_n & 2\sum x_i^2 \end{pmatrix}$$

$\det(H) = 4n \sum (x_i - \bar{x}_n)^2 > 0 \implies$ Minimum global unique concave.

$$\hat{\beta}_n = \frac{\sum_{j=1}^n (x_j - \bar{x}_n) y_j}{\sum_{j=1}^n (x_j - \bar{x}_n)^2} = \frac{\sum x_j y_j - n \bar{x}_n \bar{y}_n}{\sum x_j^2 - n \bar{x}_n^2}$$

$\hat{a}_n = \bar{y}_n - \hat{\beta}_n \bar{x}_n \implies$ passe par $(\bar{x}_n, \bar{y}_n)$

5.2 Propriétés des Résidus

$$r_j = y_j - \hat{y}_j = y_j - (\hat{a}_n + \hat{\beta}_n x_j) \\ \sum_{j=1}^n r_j = 0 \quad \sum_{j=1}^n x_j r_j = 0 = \sum_{j=1}^n \hat{y}_j r_j$$

5.3 Analyse de la Variance (ANOVA)

Décomposition de la somme des carrés totale :

$$\sum_{j=1}^n (y_j - \bar{y}_n)^2 = \sum_{j=1}^n (\hat{y}_j - \bar{y}_n)^2 + \sum_{j=1}^n r_j^2$$

$$\implies SC_{\text{Total}} = SC_R + SC_E$$

• **Coefficient de détermination R^2 :** Proportion de variance expliquée.

$$R^2 = \frac{SC_R}{SC_{\text{Total}}} = 1 - \frac{SC_E}{SC_{\text{Total}}}$$

• **R^2 Ajusté :** Corrige l'inflation artificielle due au nombre de variables.

$$R_{\text{adj}}^2 = 1 - \frac{SC_E / (n - 2)}{SC_{\text{Total}} / (n - 1)}$$

• **Estimation sans biais du bruit σ^2 :** $S_n^2 = \frac{SC_E}{n-2} = \frac{1}{n-2} \sum_{j=1}^n r_j^2$.

5.4 Inférence Statistique sur la Pente β

• **Distribution exacte :** $\hat{\beta}_n \sim \mathcal{N}(\beta, \sigma^2 / \sum (x_i - \bar{x}_n)^2)$.

• **Erreur-type de la pente :** $\hat{sd}(\hat{\beta}_n) = S_n / \sqrt{\sum (x_i - \bar{x}_n)^2}$.

• **Pivot associé :** $\frac{\hat{\beta}_n - \beta}{\hat{sd}(\hat{\beta}_n)} \sim t_{n-2}$.

• **IC bilatéral $(1 - \alpha)$:** $\left[\hat{\beta}_n \pm t_{n-2, 1-\alpha/2} \times \hat{sd}(\hat{\beta}_n) \right]$.

• **Test d'hypothèse $H_0 : \beta = \beta_0$ vs $H_1 : \beta \neq \beta_0$:** Statistique $t_{\text{obs}} = \frac{\hat{\beta}_n - \beta_0}{\hat{sd}(\hat{\beta}_n)}$. On rejette $H_0 \iff |t_{\text{obs}}| > t_{n-2, 1-\alpha/2}$.

5.5 Imputation & Prédiction

Pour une nouvelle valeur x_+ , la prévision de la réponse est $\hat{y}_+ = \hat{a}_n + \hat{\beta}_n x_+$.

6 Distributions, Moments & Estimations

Loi	Support	$f(x)$ ou $\mathbb{P}(X=x)$	$\mathbb{E}(X)$	$Var(X)$
$U(0, \theta)$	$[0, \theta]$	$\frac{1}{\theta}$	$\frac{\theta}{2}$	$\frac{\theta^2}{12}$
$\exp(\lambda)$	$[0, +\infty[$	$\lambda e^{-\lambda x}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
Poiss(λ)	$\mathbb{N}$	$\frac{\lambda^x}{x!} e^{-\lambda}$	λ	λ
$\mathcal{B}(m, p)$	$\{0, \dots, m\}$	$\binom{m}{x} p^x (1-p)^{m-x}$	mp	$mp(1-p)$
$\mathcal{N}(\mu, \sigma^2)$	$\mathbb{R}$	$\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	μ	σ^2

6.1 Résultats d'Estimation & Fisher par Loi

• **Uniforme $U(0, \theta)$:** $\hat{\theta}_{MOM} = 2\bar{X}_n$, $\hat{\theta}_{ML} = M_n = \max(X_i)$. Modèle non régulier (pas d'information de Fisher standard via dérivée).

• **Exponentielle $\exp(\lambda)$:** $\hat{\lambda}_{ML} = 1/\bar{X}_n$. Score $l'(\lambda) = \frac{n}{\lambda} - n\bar{X}_n$, $l''(\lambda) = -n/\lambda^2$. Information théorique $I_1(\lambda) = 1/\lambda^2 \implies I_n(\lambda) = n/\lambda^2$. Information observée $J_n(\hat{\lambda}_{ML}) = n\bar{X}_n^2$.

• **Poisson Poiss(λ) :** $\hat{\lambda}_{ML} = \bar{X}_n$. Score $l'(\lambda) = \frac{n\bar{X}_n}{\lambda} - n$, $l''(\lambda) = -\frac{n\bar{X}_n}{\lambda^2}$. Information théorique $I_1(\lambda) = 1/\lambda \implies I_n(\lambda) = n/\lambda$. Information observée $J_n(\hat{\lambda}_{ML}) = n/\bar{X}_n$.

• **Binomiale $\mathcal{B}(m, p)$ (m connu) :** $\hat{p}_{ML} = \bar{X}_n/m$. Log-vraisemblance : $l(p) = n\bar{X}_n \log p + (nm - n\bar{X}_n) \log(1-p) + cst.$ Dérivée seconde : $l''(p) = -\frac{n\bar{X}_n}{p^2} -$

$\frac{nm - n\bar{X}_n}{(1-p)^2}$. Information théorique $I_1(p) = \frac{nm}{p(1-p)} \implies I_n(p) = \frac{nm}{p(1-p)}$.

• **Normale $\mathcal{N}(\mu, \sigma^2)$:** $\hat{\mu}_{ML} = \bar{X}_n$, $\hat{\sigma}_{ML}^2 = \hat{\sigma}_n^2$. Information pour μ (si σ^2 connu) : $I_n(\mu) = n/\sigma^2$.

6.2 Loi Normale Standard $\mathcal{N}(0, 1)$

• Densité $\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$, symétrique autour de 0. Fonction de répartition : $\Phi(z) = \int_{-\infty}^z \phi(x) dx$.

• Propriétés cruciales des quantiles : $\Phi(-z) = 1 - \Phi(z)$. $\mathbb{P}(z_1 \leq Z \leq z_2) = \Phi(z_2) - \Phi(z_1)$.

• Seuils empiriques : $\mathbb{P}(|Z| \leq 1) \approx 68.3\%$, $\mathbb{P}(|Z| \leq 1.96) = 95\%$, $\mathbb{P}(|Z| \leq 2.58) = 99\%$.

6.3 Tests Khi-deux (χ^2)

Adéquation : k classes, o_i obs, e_i théo ($\sum o_i = \sum e_i = n$, $e_i \geq 5$).

$$T_n = \sum_{i=1}^k \frac{(o_i - e_i)^2}{e_i} \overset{app}{\rightarrow} \chi_\nu^2$$

$\nu = k-1$ (sans estimation) $\nu = k-1-c$ (c param. estimés). Rejet $H_0 \iff t_{\text{obs}} > \chi_{\nu, 1-\alpha}^2$ $p_{\text{obs}} = \mathbb{P}(T \geq t_{\text{obs}})$.

Indépendance (Contingence) : Caractères A (h classes), B (k classes).

$$e_{ij} = \frac{n_{i.} n_{.j}}{n} \implies t_{\text{obs}} = \sum_{i=1}^h \sum_{j=1}^k \frac{(n_{ij} - e_{ij})^2}{e_{ij}}$$

$\nu = (h-1)(k-1)$ Rejet $\iff t_{\text{obs}} > \chi_{(h-1)(k-1), 1-\alpha}^2$.

7 Inégalités

Markov : Soit X une var aléatoire et $X \geq 0$ et $a > 0$: $\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}(X)}{a}$

7.1 Propriété de Perte de Mémoire

Une loi est dite **sans mémoire** si $\mathbb{P}(X > s+t \mid X > s) = \mathbb{P}(X > t)$.

Type	Loi	Mémoire
Continu	$\exp(\lambda)$	Aucune
Discret	Géométrique $p(1-p)^{k-1}$	Aucune
Autres	Poiss(λ)	Processus

7.2 Propriétés de la Loi de Poisson (Poiss)

• **Processus Poisson :** Si temps inter-événements sont $T_i \overset{iid}{\sim} \text{Exp}(\lambda)$, le nombre d'événements $N(t)$ sur un intervalle t suit : $N(t) \sim \text{Poiss}(\lambda t)$

• **Approx d'événements rares :** Lim d'une Binomiale $\mathcal{B}(n, p)$ quand $n \rightarrow \infty$ et $p \rightarrow 0$ avec $np = \lambda$: $X \sim \mathcal{B}(n, p) \xrightarrow{\mathcal{L}} \text{Poiss}(\lambda)$

• **Stabilité par sommation :** Si $X \sim \text{Poiss}(\lambda_1)$ et $Y \sim \text{Poiss}(\lambda_2)$ sont indépendantes :

$$X + Y \sim \text{Poiss}(\lambda_1 + \lambda_2)$$