

1 Statistique Exploratoire

Soit un échantillon univarié ordonné :
 $y_{(1)} \leq y_{(2)} \leq \dots \leq y_{(n)}$.

1.1 Tendence centrale

- **Moyenne empirique** : $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$. Très sensible aux valeurs aberrantes.
- **Médiane** ($med(y)$) : Indicateur robuste (résistant).

Si n impair : $med(y) = y_{(\lceil n/2 \rceil)}$

Si n pair : $med(y) = \frac{1}{2} (y_{(n/2)} + y_{(n/2+1)})$

- **Quantile d'ordre** $p \in (0, 1)$: $\hat{q}(p) = y_{(\lceil np \rceil)}$.
- **Quartiles** : Inférieur $\hat{q}(0.25) = y_{(\lceil n/4 \rceil)}$, Supérieur $\hat{q}(0.75) = y_{(\lceil 3n/4 \rceil)}$.

1.2 Dispersion & Forme

- **Variance empirique** (s^2) : Division par $(n-1)$ pour corriger le biais. Formule de König-Huygens empirique associée :

$$s^2 = \frac{1}{n-1} \sum_{j=1}^n (y_j - \bar{y})^2$$
$$= \frac{1}{n-1} \left(\sum_{j=1}^n y_j^2 - n\bar{y}^2 \right)$$

- **Écart-type empirique** : $s = \sqrt{s^2}$.
- **Étendue (Range)** : $y_{(n)} - y_{(1)}$.
- **Étendue interquartile** : $IQR(y) = \hat{q}(0.75) - \hat{q}(0.25)$.
- **Boxplot** : Construit sur la *five-number summary* ($y_{(1)}, \hat{q}(0.25), med, \hat{q}(0.75), y_{(n)}$). Seuil maximal des moustaches : $C = 1.5 \times IQR$. Les moustaches s'arrêtent aux valeurs réelles les plus extrêmes contenues dans $[\hat{q}(0.25) - C, \hat{q}(0.75) + C]$. Les points au-delà sont des valeurs aberrantes.

2 Théorie des Probabilités & Théorèmes

2.1 Propriétés des Espérances conditionnelles

- **Théorème de l'espérance totale** : Soit une partition de l'espace fondamental $A_1, A_2, \dots$

$$\mathbb{E}(X) = \sum_i \mathbb{E}(X|A_i) \mathbb{P}(A_i)$$

2.2 Covariance & Corrélation théoriques

- **Covariance** : Mesure de dépendance linéaire.

$$cov(X, Y) = \mathbb{E}[\{X - \mathbb{E}(X)\}\{Y - \mathbb{E}(Y)\}] = \mathbb{E}(\mathbf{XY}) - \mathbb{E}(\mathbf{X})\mathbb{E}(\mathbf{Y})$$

Propriétés de la covariance :

1. $cov(X, Y) = cov(Y, X)$ et $cov(X, X) = var(X)$.
2. Bilinéarité : $cov(X + Y, Z + W) = cov(X, Z) + cov(Y, Z) + cov(X, W) + cov(Y, W)$.
3. Changement d'échelle : $cov(aX + b, cY + d) = ac \cdot cov(X, Y)$.
4. Variance d'une somme/différence : $var(X \pm Y) = var(X) + var(Y) \pm 2cov(X, Y)$.

5. Si X, Y indépendantes $\implies cov(X, Y) = 0$ (la réciproque est fausse).

- **Corrélation** ($\rho_{X,Y}$) : Dimensionnelle, normalisée par Cauchy-Schwarz.

$$\rho_{X,Y} = \frac{cov(X, Y)}{\sqrt{var(X)var(Y)}} \implies -1 \leq \rho_{X,Y} \leq 1$$

Propriétés de la corrélation :

1. $\rho(a + bX, c + dY) = \text{sign}(bd)\rho(X, Y)$.
2. $\rho(X, X) = 1$ et $\rho(X, -X) = -1$ (si X non constante).
3. $\rho_{X,Y} = 0$ n'implique pas l'indépendance (relation non linéaire possible).

- **Corrélation empirique** : Pour un échantillon de paires $(x_1, y_1), \dots, (x_n, y_n)$:

$$r = \frac{\sum_{j=1}^n (x_j - \bar{x})(y_j - \bar{y})}{\sqrt{\sum_{j=1}^n (x_j - \bar{x})^2 \sum_{j=1}^n (y_j - \bar{y})^2}}$$

2.3 Comportements Limites (LGN)

Soit $X_1, X_2, \dots$ une suite de variables i.i.d. d'espérance μ .

- **Loi faible des grands nombres** : Si $var(X_1) < \infty$, alors pour tout $\epsilon > 0$:

$$\mathbb{P}(|\bar{X}_n - \mu| \geq \epsilon) \rightarrow 0 \quad \text{quand } n \rightarrow \infty$$

Convergence en proba

- **Loi forte des grands nombres** : Nécessite uniquement $\mathbb{E}(X_1) < \infty$:

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} \bar{X}_n = \mu\right) = 1$$

Convergence quasi sûre

2.4 Théorème Central Limite (TCL) & Delta

- **TCL** : Si $0 < \sigma^2 = var(X_i) < \infty$, alors la variable standardisée converge en loi :

$$Z_n = \frac{\bar{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$$

$$\implies \bar{X}_n \overset{app}{\approx} \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

- **Méthode Delta** : Soit g une fonction continûment dérivable en μ telle que $g'(\mu) \neq 0$. Alors :

$$\sqrt{n} \frac{g(\bar{X}_n) - g(\mu)}{\sigma} \xrightarrow{\mathcal{L}} \mathcal{N}(0, [g'(\mu)]^2)$$
$$\implies g(\bar{X}_n) \overset{app}{\approx} \mathcal{N}\left(g(\mu), \frac{[g'(\mu)]^2 \sigma^2}{n}\right)$$

2.5 Quantiles théoriques

Pour une fonction de répartition F , le p -ième quantile est $x_p = \inf\{x : F(x) \geq p\}$. Si F est continue et strictement croissante, $x_p = F^{-1}(p)$. La médiane théorique correspond à $x_{0.5}$.

3 Estimation Ponctuelle

Soit un échantillon $X_1, \dots, X_n \overset{iid}{\sim} f(x; \theta)$.

3.1 Méthode des Moments (MOM)

Égalisation des moments théoriques $m_k(\theta) = \mathbb{E}_\theta(X^k)$ et empiriques $\hat{m}_k = \frac{1}{n} \sum X_i^k$.

3.2 Maximum de Vraisemblance (ML)

Vraisemblance $L(\theta) = \prod_{i=1}^n f(x_i; \theta)$, et log-vraisemblance $l(\theta) = \sum_{i=1}^n \log f(x_i; \theta)$.

L'estimateur $\hat{\theta}_{ML}$ vérifie l'équation de score $l'(\hat{\theta}_{ML}) = 0$ et la condition de concavité $l''(\hat{\theta}_{ML}) < 0$.

3.3 Propriétés & Optimisation d'EQM

- **Biais** : $b_\theta(\hat{\theta}) = \mathbb{E}_\theta(\hat{\theta}) - \theta$.
- **Erreur Quadratique Moyenne (EQM)** :

$$EQM_\theta(\hat{\theta}) = \mathbb{E}_\theta\{(\hat{\theta} - \theta)^2\} = Var_\theta(\hat{\theta}) + [b_\theta(\hat{\theta})]^2$$

- **Cas de l'estimateur de la variance sous $\mathcal{N}(\mu, \sigma^2)$** :

Soit $\hat{\sigma}_n^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$. On définit la famille d'estimateurs $\hat{\sigma}^a = a\hat{\sigma}_n^2$. Sachant que $\mathbb{E}(\hat{\sigma}_n^2) = \frac{n-1}{n}\sigma^2$ et $Var(n\hat{\sigma}_n^2) = 2\sigma^4(n-1)$:

- **Bias null** : $a = \frac{n}{n-1} \implies S_n^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$
- **Var nulle** : $a = 0 \implies$ Var nulle, EQM maximal ($= \sigma^2$)
- **Min l'EQM** : $a = \frac{n}{n+1} \implies \frac{1}{n+1} \sum (X_i - \bar{X})^2$

3.4 Information de Fisher & Asymptotique

- **Information de Fisher (un échantillon)** :

$$I_1(\theta) = -\mathbb{E}_\theta \left[\frac{\partial^2}{\partial \theta^2} \log f(X_1; \theta) \right]$$

$$\implies I_n(\theta) = n \cdot I_1(\theta) = -\mathbb{E}_\theta(l''(\theta))$$

- **Information de Fisher observée** : $J_n(\hat{\theta}_{ML}) = -l''(\hat{\theta}_{ML})$.
- **Variance Asymptotique** : $\frac{1}{J_n(\hat{\theta}_{ML})}$
- **Propriété asymptotique** : Pour les modèles réguliers, quand $n \rightarrow \infty$:

$$\hat{\theta}_{ML} \overset{app}{\approx} \mathcal{N}\left(\theta, \frac{1}{I_n(\theta)}\right) \approx \mathcal{N}\left(\theta, \frac{1}{J_n(\hat{\theta}_{ML})}\right)$$

Attention : Échoue pour les modèles non réguliers où le support dépend du paramètre (ex : Uniforme $U(0, \theta)$).

3.5 Loi de Pareto (Queues Lourdes)

Densité $f(x) = \alpha x^{-1-\alpha}$ sur $[1, \infty)$ pour $\alpha > 0$. Moment d'ordre r : $\mathbb{E}(X^r) = \frac{\alpha}{\alpha-r}$ si $r < \alpha$, et ∞ si $r \geq \alpha$. Ainsi, $\mathbb{E}(X) < \infty \iff \alpha > 1$ et $Var(X) < \infty \iff \alpha > 2$. Si les moments n'existent pas, le TCL et les propriétés standard des variances/corrélations s'effondrent.

4 Intervalles de Confiance (IC)

4.1 Théorie des Pivots

$T(Y, \theta)$ est un **pivot** si sa loi exacte est connue et indépendante de θ . On résout $\mathbb{P}_\theta(a \leq T(Y, \theta) \leq b) = 1 - \alpha$ pour isoler θ .

4.2 IC - Cas de la Loi Normale $\mathcal{N}(\mu, \sigma^2)$

• Si σ^2 connue : Pivot $Z_n = \sqrt{n} \frac{\bar{Y}_n - \mu}{\sigma} \sim \mathcal{N}(0, 1)$.

$$\text{IC bilatéral } (1 - \alpha) : \left[\bar{Y}_n \pm \frac{z_{1-\alpha/2}}{\sqrt{n}} \sigma \right]$$

• Si σ^2 inconnue : Estimée par S_n^2 . Pivot $T_n = \sqrt{n} \frac{\bar{Y}_n - \mu}{S_n} \sim t_{n-1}$.

$$\text{IC bilatéral } (1 - \alpha) : \left[\bar{Y}_n \pm \frac{t_{n-1, 1-\alpha/2}}{\sqrt{n}} S_n \right]$$

IC unilatéral gauche :

$$\left[\bar{Y}_n - \frac{t_{n-1, 1-\alpha}}{\sqrt{n}} S_n, +\infty \right]$$

• **Propriété des quantiles** : La loi de Student ayant des queues plus lourdes, $|t_{n-1, \beta}| > |z_\beta|$ pour tout $\beta \neq 0.5$. Quand $n \rightarrow \infty$, $t_{n-1} \rightarrow \mathcal{N}(0, 1)$.

4.3 Pivots Exact Non Normaux

• **Cas Uniforme** $U(0, \theta)$: Soit $M_n = \max(Y_i)$. Le pivot est $T = \frac{M_n}{\theta}$. Fonction de répartition : $F_T(t) = \mathbb{P}_\theta(T \leq t) = t^n$ pour $t \in (0, 1)$. Pour un niveau $1 - \alpha$, en choisissant l'intervalle symétrique en probabilité sur T : $\mathbb{P}_\theta(\alpha^{1/n} \leq T \leq 1) = 1 - \alpha$. En inversant :

$$\text{IC exact } (1 - \alpha) : \left[M_n, \alpha^{-1/n} M_n \right]$$

4.4 IC Asymptotiques ($n \rightarrow \infty$)

• **Via l'EMV et l'Information observée** :

$$\theta \in \left[\hat{\theta}_{ML} \pm \frac{z_{1-\alpha/2}}{\sqrt{J_n(\hat{\theta}_{ML})}} \right]$$

• **Via le TCL (Exemple de la loi Uniforme $U(0, \theta)$)** :

$$\mathbb{E}(Y) = \frac{\theta}{2}, \text{Var}(Y) = \frac{\theta^2}{12} \implies Z_n = \frac{\sqrt{n}(\bar{Y}_n - \theta/2)}{\sqrt{\theta^2/12}} \stackrel{app}{\sim} \mathcal{N}(0, 1). \text{ En résolvant l'inéquation } |Z_n| \leq z_{1-\alpha/2} \text{ par rapport à } \theta, \text{ on obtient :}$$

$$\theta \in \left[\frac{\bar{Y}_n}{\frac{1}{2} + \frac{z_{1-\alpha/2}}{\sqrt{12n}}}, \frac{\bar{Y}_n}{\frac{1}{2} - \frac{z_{1-\alpha/2}}{\sqrt{12n}}} \right]$$

5 Régression Linéaire Simple

Modèle : $y_j = a + \beta x_j + \epsilon_j$ avec $\epsilon_j \stackrel{iid}{\sim} \mathcal{N}(0, \sigma^2)$ et x_j fixés non tous égaux.

5.1 Optimisation & Moindres Carrés (MCO)

Minimisation de la somme des carrés résiduels $S(a, \beta) = \sum \{y_j - (a + \beta x_j)\}^2$. Matrice Hessienne globale du système :

$$H = \begin{pmatrix} 2n & 2n\bar{x}_n \\ 2n\bar{x}_n & 2\sum x_j^2 \end{pmatrix}$$

$\det(H) = 4n \sum (x_i - \bar{x}_n)^2 > 0 \implies$ Minimum global unique concave.

$$\hat{\beta}_n = \frac{\sum_{j=1}^n (x_j - \bar{x}_n) y_j}{\sum_{j=1}^n (x_j - \bar{x}_n)^2} = \frac{\sum x_j y_j - n \bar{x}_n \bar{y}_n}{\sum x_j^2 - n \bar{x}_n^2}$$

$$\hat{a}_n = \bar{y}_n - \hat{\beta}_n \bar{x}_n \implies \text{passe par } (\bar{x}_n, \bar{y}_n)$$

5.2 Propriétés des Résidus

Résidus définis par $r_j = y_j - \hat{y}_j = y_j - (\hat{a}_n + \hat{\beta}_n x_j)$.

$$\sum_{j=1}^n r_j = 0, \quad \sum_{j=1}^n x_j r_j = 0, \quad \sum_{j=1}^n \hat{y}_j r_j = 0$$

5.3 Analyse de la Variance (ANOVA)

Décomposition de la somme des carrés totale :

$$\sum_{j=1}^n (y_j - \bar{y}_n)^2 = \sum_{j=1}^n (\hat{y}_j - \bar{y}_n)^2 + \sum_{j=1}^n r_j^2 \implies SC_{\text{Total}} = SC_R + SC_E$$

• **Coefficient de détermination R^2** : Proportion de variance expliquée.

$$R^2 = \frac{SC_R}{SC_{\text{Total}}} = 1 - \frac{SC_E}{SC_{\text{Total}}}$$

• **R^2 Ajusté** : Corrige l'inflation artificielle due au nombre de variables.

$$R_{\text{adj}}^2 = 1 - \frac{SC_E / (n - 2)}{SC_{\text{Total}} / (n - 1)}$$

• **Estimation sans biais du bruit σ^2** : $S_n^2 = \frac{SC_E}{n-2} = \frac{1}{n-2} \sum_{j=1}^n r_j^2$.

5.4 Inférence Statistique sur la Pente β

• **Distribution exacte** : $\hat{\beta}_n \sim \mathcal{N}(\beta, \sigma^2 / \sum (x_i - \bar{x}_n)^2)$.

• **Erreur-type de la pente** : $\hat{sd}(\hat{\beta}_n) = S_n / \sqrt{\sum (x_i - \bar{x}_n)^2}$.

• **Pivot associé** : $\frac{\hat{\beta}_n - \beta}{\hat{sd}(\hat{\beta}_n)} \sim t_{n-2}$.

• **IC bilatéral** ($1 - \alpha$) : $\left[\hat{\beta}_n \pm t_{n-2, 1-\alpha/2} \times \hat{sd}(\hat{\beta}_n) \right]$.

• **Test d'hypothèse $H_0 : \beta = \beta_0$ vs $H_1 : \beta \neq \beta_0$** : Statistique $t_{\text{obs}} = \frac{\hat{\beta}_n - \beta_0}{\hat{sd}(\hat{\beta}_n)}$. On rejette $H_0 \iff |t_{\text{obs}}| > t_{n-2, 1-\alpha/2}$.

5.5 Imputation & Prédiction

Pour une nouvelle valeur x_+ , la prévision de la réponse est $\hat{y}_+ = \hat{a}_n + \hat{\beta}_n x_+$.

5.6 Lien avec le Maximum de Vraisemblance

La log-vraisemblance globale du modèle gaussien s'écrit :

$$l(a, \beta, \sigma^2) =$$

$$-\frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{j=1}^n \{y_j - (a + \beta x_j)\}^2 - \frac{n}{2} \log(2\pi)$$

Maximiser l donne les mêmes estimateurs $\hat{a}_{ML} = \hat{a}_{MCO}$ et $\hat{\beta}_{ML} = \hat{\beta}_{MCO}$. Cependant, l'estimateur ML de la variance est biaisé : $\hat{\sigma}_{ML}^2 = \frac{1}{n} \sum r_j^2 = \frac{n-2}{n} S_n^2$.

6 Distributions, Moments & Estimations

Loi	Support	$f(x)$ ou $\mathbb{P}(X=x)$	$\mathbb{E}(X)$	$\text{Var}(X)$
$U(0, \theta)$	$[0, \theta]$	$\frac{1}{\theta}$	$\frac{\theta}{2}$	$\frac{\theta^2}{12}$
$\exp(\lambda)$	$[0, +\infty[$	$\lambda e^{-\lambda x}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
$\text{Pois}(\lambda)$	$\mathbb{N}$	$\frac{\lambda^x}{x!} e^{-\lambda}$	λ	λ
$\mathcal{B}(m, p)$	$\{0, \dots, m\}$	$\binom{m}{x} p^x (1-p)^{m-x}$	mp	$mp(1-p)$
$\mathcal{N}(\mu, \sigma^2)$	$\mathbb{R}$	$\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	μ	σ^2

6.1 Résultats d'Estimation & Fisher par Loi

• **Uniforme** $U(0, \theta)$: $\hat{\theta}_{MOM} = 2\bar{X}_n$, $\hat{\theta}_{ML} = M_n = \max(X_i)$. Modèle non régulier (pas d'information de Fisher standard via dérivée).

• **Exponentielle** $\exp(\lambda)$: $\hat{\lambda}_{ML} = 1/\bar{X}_n$. Score $l'(\lambda) = \frac{n}{\lambda} - n\bar{X}_n$, $l''(\lambda) = -n/\lambda^2$. Information théorique $I_1(\lambda) = 1/\lambda^2 \implies I_n(\lambda) = n/\lambda^2$. Information observée $J_n(\hat{\lambda}_{ML}) = n\bar{X}_n^2$.

• **Poisson** $\text{Pois}(\lambda)$: $\hat{\lambda}_{ML} = \bar{X}_n$. Score $l'(\lambda) = \frac{n\bar{X}_n}{\lambda} - n$, $l''(\lambda) = -\frac{n\bar{X}_n}{\lambda^2}$. Information théorique $I_1(\lambda) = 1/\lambda \implies I_n(\lambda) = n/\lambda$. Information observée $J_n(\hat{\lambda}_{ML}) = n/\bar{X}_n$.

• **Binomiale** $\mathcal{B}(m, p)$ (m connu) : $\hat{p}_{ML} = \bar{X}_n/m$. Log-vraisemblance : $l(p) = n\bar{X}_n \log p + (nm - n\bar{X}_n) \log(1-p) + \text{cst.}$ Dérivée seconde : $l''(p) = -\frac{n\bar{X}_n}{p^2} - \frac{nm - n\bar{X}_n}{(1-p)^2}$. Information théorique $I_1(p) = \frac{nm}{p(1-p)} \implies I_n(p) = \frac{nm}{p(1-p)}$.

• **Normale** $\mathcal{N}(\mu, \sigma^2)$: $\hat{\mu}_{ML} = \bar{X}_n$, $\hat{\sigma}_{ML}^2 = \hat{\sigma}_n^2$. Information pour μ (si σ^2 connu) : $I_n(\mu) = n/\sigma^2$.

6.2 Loi Normale Standard $\mathcal{N}(0, 1)$

• Densité $\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$, symétrique autour de 0. Fonction de répartition : $\Phi(z) = \int_{-\infty}^z \phi(x) dx$.

• Propriétés cruciales des quantiles : $\Phi(-z) = 1 - \Phi(z)$. $\mathbb{P}(z_1 \leq Z \leq z_2) = \Phi(z_2) - \Phi(z_1)$.

• Seuils empiriques : $\mathbb{P}(|Z| \leq 1) \approx 68.3\%$, $\mathbb{P}(|Z| \leq 1.96) = 95\%$, $\mathbb{P}(|Z| \leq 2.58) = 99\%$.

6.3 Tests Khi-deux (χ^2)

Adéquation : k classes, o_i obs, e_i théo ($\sum o_i = \sum e_i = n$, $e_i \geq 5$).

$$T_n = \sum_{i=1}^k \frac{(o_i - e_i)^2}{e_i} \xrightarrow{app} \chi_\nu^2$$

$\nu = k - 1$ (sans estimation) $\nu = k - 1 - c$ (c param. estimés). Rejet $H_0 \iff t_{\text{obs}} > \chi_{\nu, 1-\alpha}^2$ $p_{\text{obs}} = \mathbb{P}(T \geq t_{\text{obs}})$.

Indépendance (Contingence) : Caractères A (h classes), B (k classes).

$$e_{ij} = \frac{n_{i.} n_{.j}}{n} \implies t_{\text{obs}} = \sum_{i=1}^h \sum_{j=1}^k \frac{(n_{ij} - e_{ij})^2}{e_{ij}}$$

$\nu = (h-1)(k-1)$ Rejet $\iff t_{\text{obs}} > \chi_{(h-1)(k-1), 1-\alpha}^2$.